Telkom University Purwokerto

Visualisasi Data

MIDTERM PROJECT VISUALISASI DATA

Time Series Analysis & Visualization
Volume Lalu Lintas I-94 (2012-2018)



Dosen Pengampu: Dasril Aldo, S.Kom., M.Kom.

Anggota:

1. M. Aulia Muzzaki Nugraha (2311102051)
2. Faqih Abdullah (2311102048)
3. Muhamad Nasrulloh (2311102044)
4. Raihan Ramadhan (2311102040)
5. Bayu Kuncoro Adi (2311102031)

S1IF-11-GAB-02

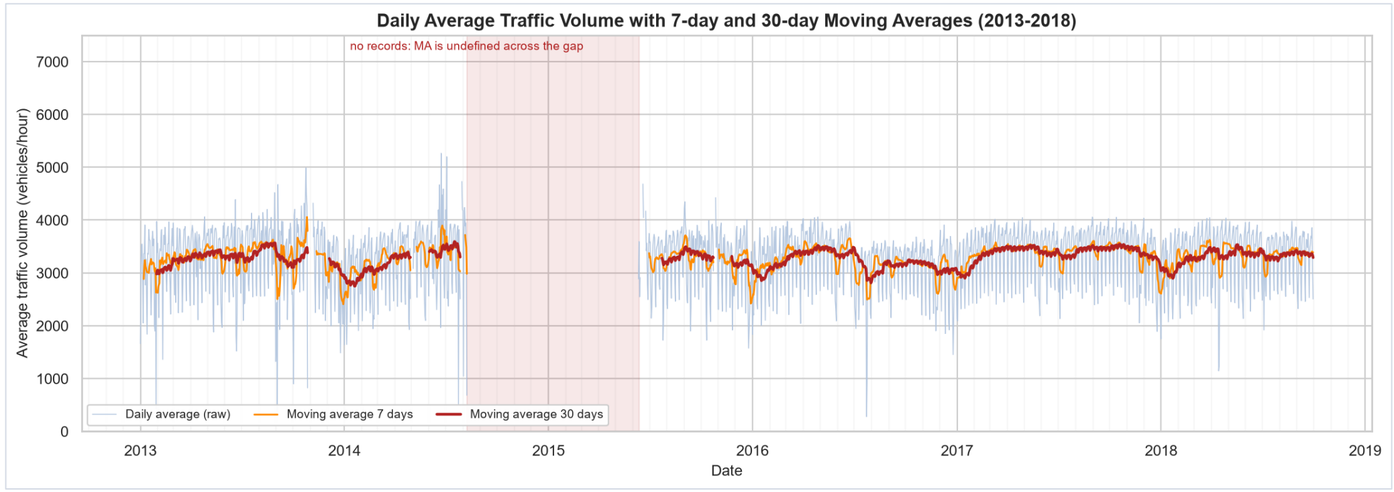
PENDAHULUAN

LATAR BELAKANG

- Lalu lintas antar-kota berubah menurut jam, hari, dan musim.
- Pemantauan per jam memberi deret panjang, tetapi rawan cela data.
- Pertanyaan: pola apa yang terbentuk, dan adakah tren panjang?

DATA YANG DIGUNAKAN

- UCI Dataset 492: 48.204 observasi per jam (Okt 2012 – Sep 2018)
- Interstate 94 arah barat, Minneapolis – St. Paul
- Variabel utama: date_time dan traffic_volume



Volume per jam, rata-rata harian, dan MA 30 hari (2013-2018).

DATASET & SUMBER

48.204
observasi per jam

9
kolom (2 utama)

11.976
jam hilang (22,8%)

5.445
timestamp duplikat

2
baris volume = 0

VARIABEL

- date_time: waktu observasi per jam, kronologis.
- traffic_volume: kendaraan per jam (variabel utama).
- Pendukung: holiday, temp, rain_1h, snow_1h, clouds_all, weather_main, weather_description.

KONDISI DATA

- 11.976 dari 52.551 jam tidak tercatat; terbesar 7.386 jam berturut-turut (2014-2015).
- Semua timestamp ganda punya traffic_volume identik, aman diambil satu.
- Sumber: archive.ics.uci.edu/dataset/492 (diunduh via ucimlrepo).

TAHAP PREPROCESSING

Deduplikasi hanya bila traffic_volume identik; flag is_sensor_zero / is_temp_error / is_rain_error; fitur kalender (hour, day_of_week, is_weekend, month) dan gap_hours. Tidak ada imputasi jam hilang.

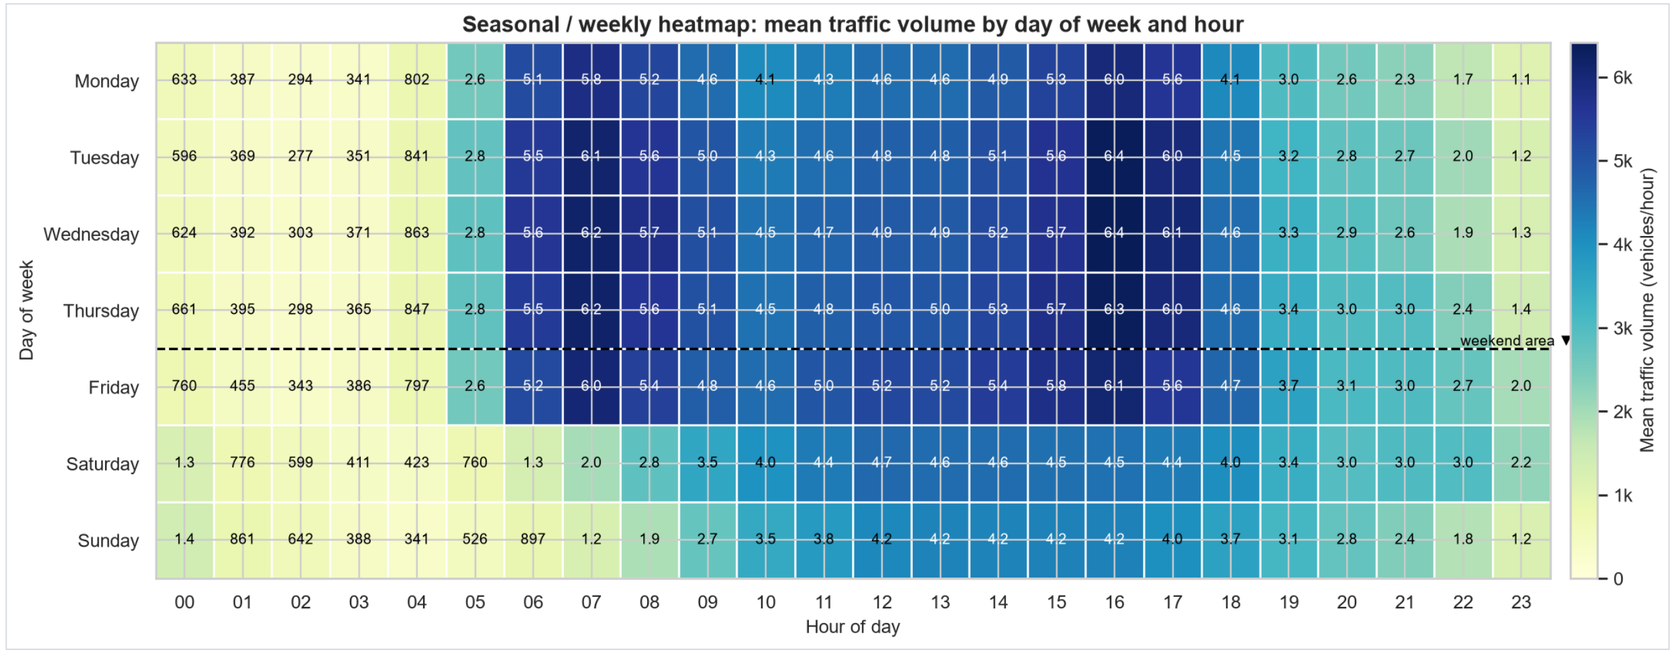
ALUR PENGOLAHAN

1. **Validasi** — Tipe data, missing value, duplikasi timestamp, celah waktu, kelengkapan harian.
2. **Preprocessing** — Deduplikasi terverifikasi, flag sentinel sensor, fitur kalender. Tanpa imputasi.
3. **Agregasi** — Rata-rata dan total per tanggal pada indeks kalender penuh (hari kosong tetap NaN).
4. **Visualisasi** — Line, area, multiple time series (direct labeling), heatmap hari x jam.
5. **Analisis tren** — Moving average 7 & 30 hari (min_periods per window) + linear fit pembanding.

TOOLS

- Python 3.12 + Jupyter Notebook
- pandas, numpy (resample, rolling)
- matplotlib, seaborn
- ucimlrepo (dataset resmi UCI 492)
- scipy (KDE pada distribusi)
- Audit otomatis 52 kriteria

POLA AKTIVITAS

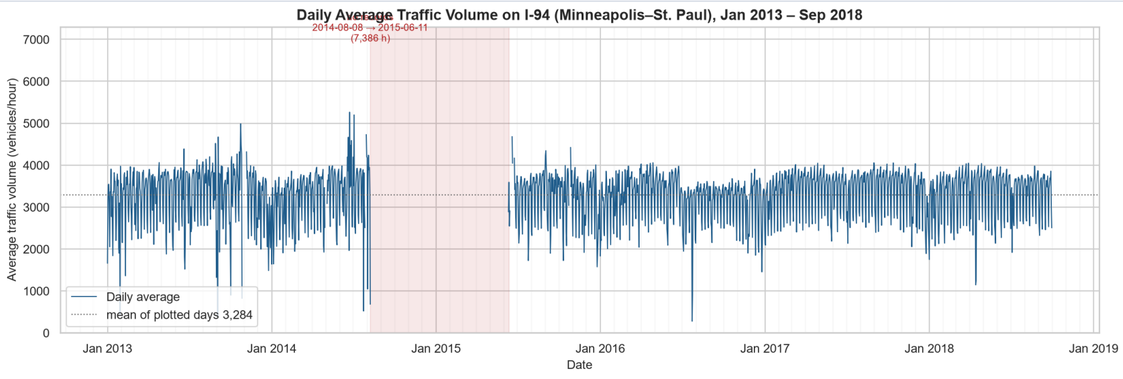


Rata-rata traffic_volume per hari dan jam (ribuan kendaraan/jam).

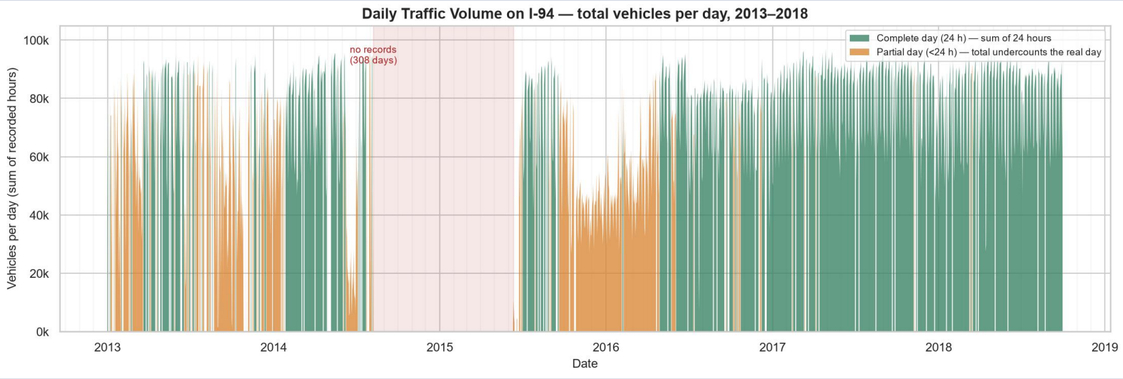
PENJELASAN

- **Hari kerja dua puncak: 16:00 dan 07:00.**
- **Sel terpadat Rabu 16:00 = 6.414 kendaraan/jam.**
- **Akhir pekan tanpa puncak pagi.**
- **Sel tersepi Selasa 02:00 = 277 kendaraan/jam.**
- **Setiap sel berisi >= 227 observasi.**

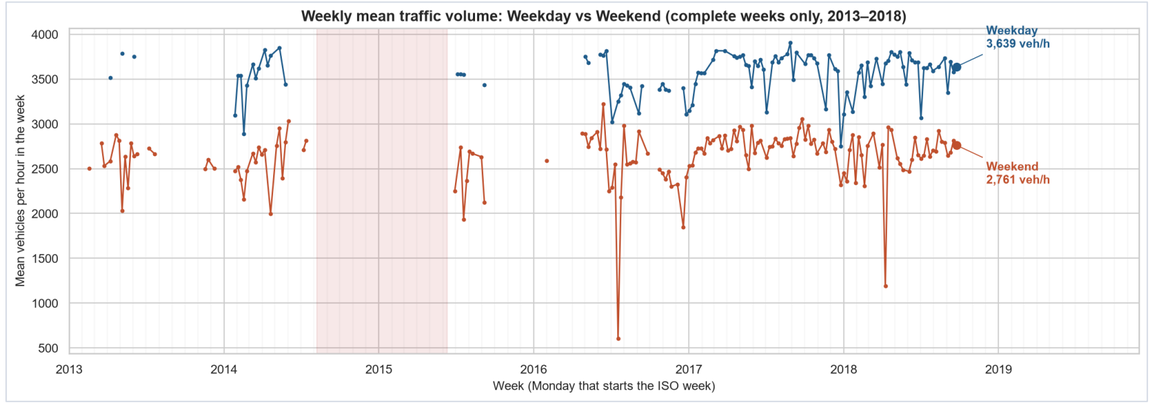
EMPAT VISUALISASI WAJIB



Line plot: rata-rata harian; pemadaman data 2014–2015 ditandai.



Area plot: total harian; hijau hari lengkap, oranye hari parsial (undercount).



Multiple time series: weekday vs weekend per minggu, direct labeling di ujung garis.

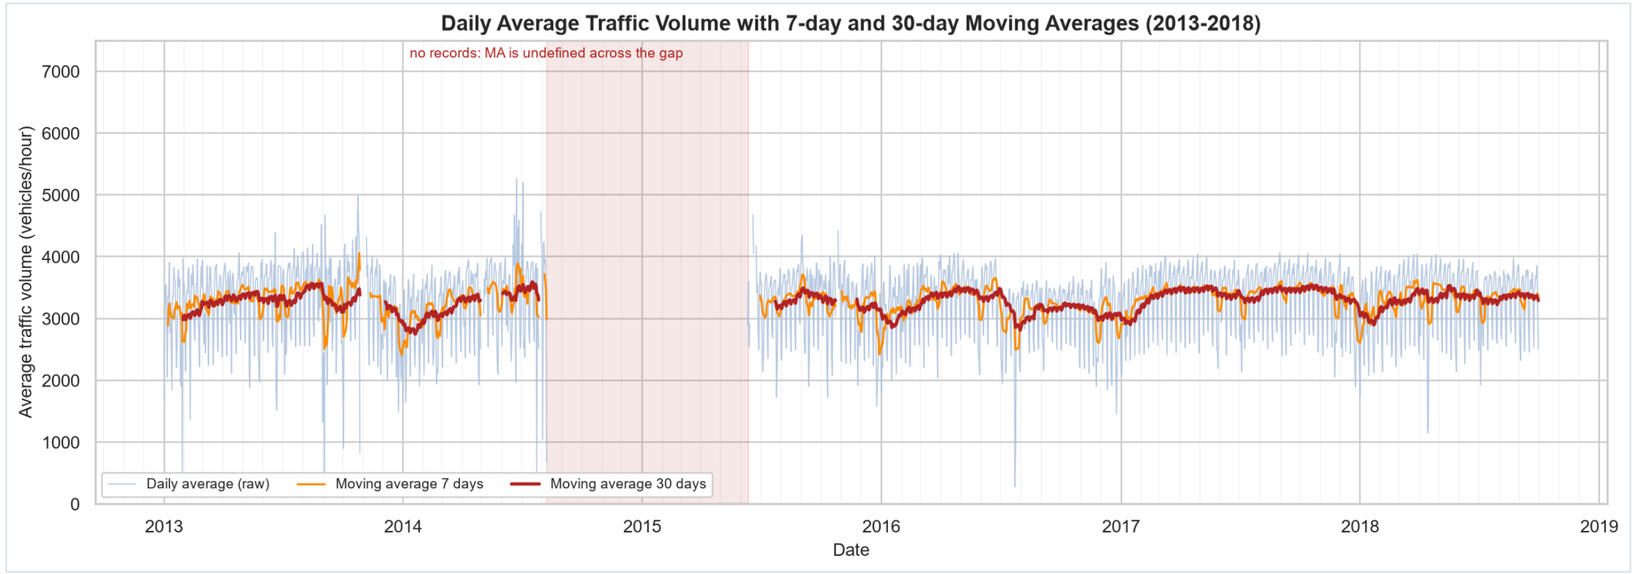
3.559
weekday, mean per jam

2.636
weekend, mean per jam

CATATAN

Weekday selalu di atas weekend. Garis terputus = minggu tidak lengkap, bukan lalu lintas nol.

ANALISIS TREN: MOVING AVERAGE



Biru muda = data asli, oranye = MA 7 hari, merah = MA 30 hari.

PARAMETER & HASIL

- rolling(window, min_periods=window) pada indeks harian.
- Standar deviasi: 604 (asli) -> 230 (MA 7) -> 167 (MA 30).
- Rentang harian: 4.986 -> 1.650 -> 843.
- NaN awal: 6 titik MA 7, 29 titik MA 30.
- Lag vs data asli: 3 hari (MA 7), 15 hari (MA 30).

WEEKDAY, WEEKEND & TREN

3.557	2.624	+934	+42	R^2 0,005
weekday, mean per jam	weekend, mean per jam	selisih (+36%)	linear fit / tahun	1.198 hari bebas celah

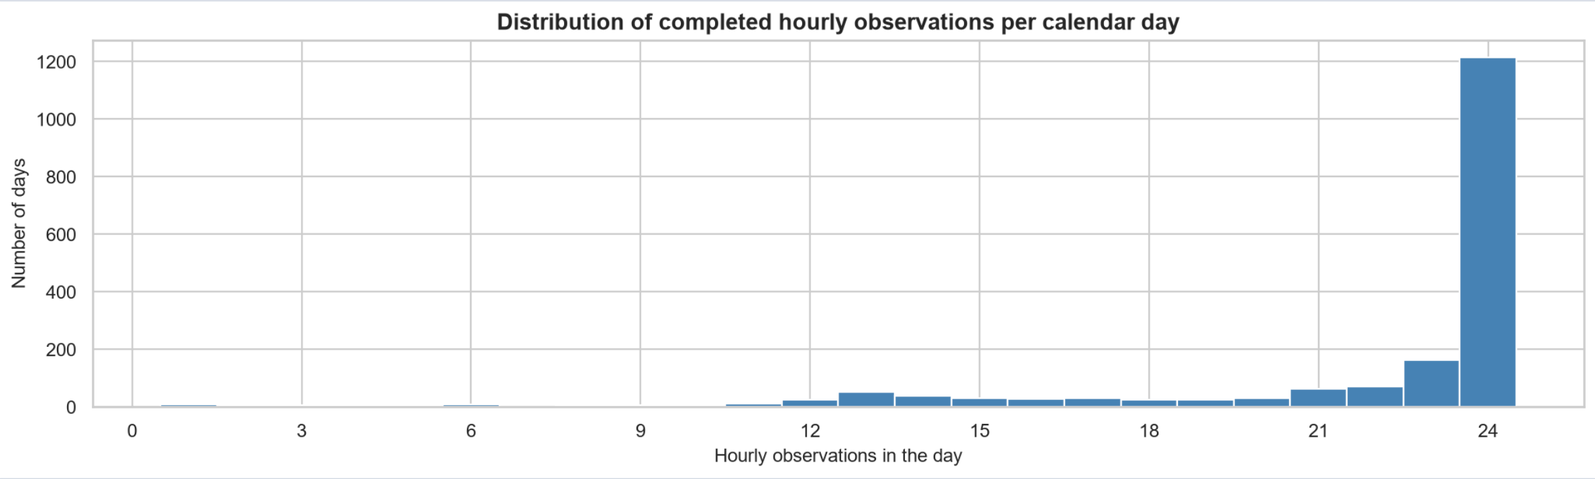
BUKTI POLA

- Jam 06:00-09:00: 5.250 (weekday) vs 2.383 (weekend).
- Porsi jam < 1.000 nyaris sama (21,7% vs 23,7%).
- Distribusi bimodal: jam malam dan jam sibuk.

BUKTI TREN

- Linear fit 2015-06 s.d. 2018-09: +42 kendaraan/jam per tahun, R^2 0,005.
- MA 30 hari datar sepanjang 2015-2018.
- Kesimpulan: tidak ada tren jangka panjang yang berarti.

VALIDASI KEANDALAN



Jumlah jam tercatat per hari (24 jam = hari lengkap).

TEMUAN

- 1.214 hari lengkap, 646 hari parsial, 330 hari tanpa rekaman.
- Hari parsial tidak dipakai untuk total harian maupun tren.

KONTROL MUTU

- Nilai traffic_volume dicek sebelum duplikat dibuang.
- Tidak ada imputasi; jam hilang tetap NaN.
- Sentinel sensor ditandai, tidak dihapus.
- SHA-256 data mentah diverifikasi.
- Run All dari kernel baru: 0 error.

FITUR TURUNAN & CARA UKUR

FITUR TURUNAN

- hour, day_of_week, is_weekend, month, year
- is_holiday (label tercatat hanya pada 00:00)
- gap_hours: jarak jam sejak observasi sebelumnya
- Flag: is_sensor_zero, is_temp_error, is_rain_error

CARA UKUR

- Mean dan median traffic_volume per jam, hari, bulan.
- Standar deviasi dan rentang sebelum vs sesudah MA.
- numpy.polyfit untuk kemiringan dan R^2.
- Jumlah observasi per sel heatmap (minimum 227).

Semua interpretasi mengacu ke angka hasil eksekusi notebook. Tidak ada klaim sebab-akibat tanpa bukti, karena data tidak memuat log kejadian atau catatan perawatan sensor.

KESIMPULAN

- Volume I-94 ditentukan kalender: jam dan jenis hari lebih berpengaruh daripada bulan.
- Hari kerja dua puncak (16:00 lalu 07:00); akhir pekan puncak siang 13:00.
- Weekday 3.557 vs weekend 2.624 kendaraan/jam (+36%).
- Tidak ada tren panjang: +42 kendaraan/jam per tahun, R^2 0,005.
- MA 30 hari paling halus, tetapi paling banyak membuang titik awal.
- 22,8% jam hilang: agregasi harian wajib memisahkan hari parsial.

Ringkasan

Empat visualisasi wajib, moving average 7 & 30 hari, dan validasi kualitas data mendukung satu kesimpulan: pola kalender jauh lebih kuat daripada tren tahunan.

Telkom University Purwokerto

Visualisasi Data

THANK YOU!

And See You The Next Project

Metro Interstate Traffic Volume | UCI Dataset ID 492

Terima kasih - pertanyaan dan diskusi dipersilakan.